

## Классификация наземных транспортных средств по параметрам авторегрессионной модели сигнала с применением нейронных сетей

Бузуверов Г.В., к.т.н. Герасимов О.И.

Формулируется задача классификации объектов движущегося наземного транспорта по типу шасси – колесному и гусеничному. Классификатор работает по сейсмическому сигналу. База экспериментальных данных содержит записи сигналов на различных трассах, дальностях и времен года. Разработана программная модель классификатора на нейронной сети с квантованием обучающего вектора, работающая в признаковом пространстве, составленном из параметров авторегрессионной модели сигнала.

### 1. Постановка задачи

Алгоритм классификации наземного транспорта является частью устройства классификации, упрощенная схема которого изображена на рис. 1. Сейсмическая волна от движущегося транспортного, поступая на датчик, преобразуется в электрический сигнал, который оцифровывается и подается на вход обнаружителя. В случае обнаружения из него извлекается вектор информативных признаков, который подается на входы классификатора. В результате их обработки на выходе классификатора формируется метка принадлежности к одному из заданных классов. Рассматриваются два класса объектов: транспортные средства с колесным шасси и транспортные средства с гусеничным шасси.

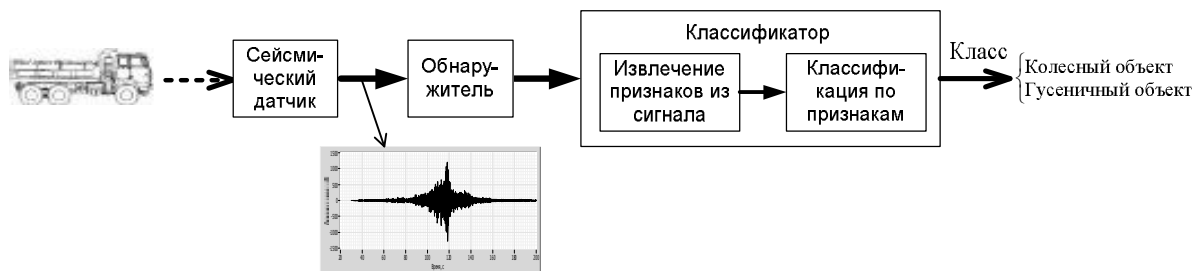


Рис.1. Задача классификации транспортных средств

При разработке классификатора используется база данных сейсмических сигналов, записанных в разные времена года на трассах с различающимися свойствами грунта. Расстояние сейсмоакустического датчика до дороги варьировалась от 20 до 200м, объекты двигались со скоростью от 10 до 60 км/час.

### 2. Авторегрессионная модель сигнала [1]

Работа классификатора предусматривает извлечение информативных признаков из сигнала. В качестве таковых берется вектор параметров авторегрессионной (АР) модели.

Спектральное оценивание в терминах АР модели используется в тех прикладных задачах, где невозможно построить корректную физическую модель поля, в частности оно используется в кодировании сигналов при передаче речевых сообщений [2]. Аксиоматика АР модели выдвигает требование стационарности сигнала как случайного процесса. В рассматриваемой задаче сигнал не является стационарным. Для работы с ним формулируется гипотеза квазистационарности, где сигнал при помощи скользящего окна разбивается на перекрывающиеся фрагменты, внутри которых отрезок сигнала рассматривается как стационарный случайный процесс, спектр которого и оценивает АР модель. Эта гипотеза нужна, чтобы обеспечить стационарность пара-

метров АР модели. На рис. 2 приведены временной сигнал в сейсмическом канале от движущегося МТЛБУ, полученный 31.08.04, и его спектрограмма. Объект двигался со скоростью  $\approx 40$  км/час. Датчик находился в 80 м от дороги.




Рис.2. Временной сигнал и спектрограмма МТЛБУ, 31.08.04,  $v \approx 40$  км/час,  $d = 80$  м

Схема с линейным предсказателем рис. 3., идеально восстанавливает процесс, если он сформирован белым шумом, прошедшим через рекурсивный фильтр  $\{a_i, i = 1, 2, \dots, n\}$ . Проиллюстрируем это при помощи рис. 3, где  $w(t_k)$  – белый шум;  $Y(t_k)$  – процесс;  $Y_P(t_k)$  – линейное предсказание;  $e(t_k)$  – ошибка линейного предсказания,  $k=1, 2, \dots, L$ .

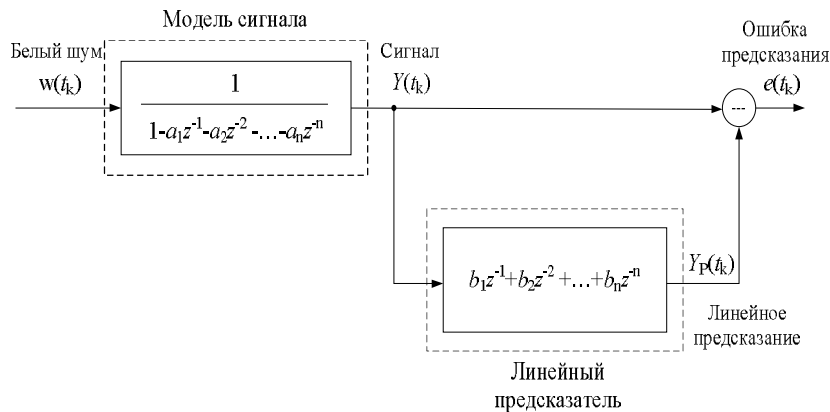


Рис.3. Схема вычисления коэффициентов АР модели сигнала

Действительно, ошибка предсказания  $e(t_k)$  равна  $Y(t_k) - Y_P(t_k) = (a_1 - b_1)Y(t_{k-1}) + \dots + (a_n - b_n)Y(t_{k-n}) + w(t_k)$ , где  $\{b_i\}$  – коэффициенты линейного предсказателя. В обозначениях  $\Delta_i = a_i - b_i$  среднеквадратичная ошибка  $E(\Delta_1, \Delta_2, \dots, \Delta_n) = \sum_{k=1}^L e(t_k)^2 = L^{-1} \sum_{k=1}^L \sum_{i=1}^n [\Delta_i Y(t_{k-i}) + w(t_k)]^2$ . Вектор параметров  $\Delta = \{\Delta_i\}$  вычисляется из условия  $\nabla E(\Delta) = 0$ , обеспечивающего  $E(\Delta) \rightarrow \min$ . Данное условие сводится к системе линейных уравнений относительно  $\Delta$ :  $\sum_{k=1}^L [\sum_{j=1}^n \Delta_j Y(t_{k-j}) + w(t_k)] Y(t_{k-s}) = 0, s = 1, 2, \dots, n$ . Т.к.  $Y(t_{k-s})$  есть линейная комбинация отсчетов белого шума  $Y(t_{k-s}) = \sum_{i=1}^s a_i w(t_{k-i})$ , то столбец свободных членов равен нулю, откуда  $a_i = b_i$ .

Ясно, что 1. реальный сигнал не подчиняется гипотезе квазистационарности, т.к. априори неизвестен временной масштаб стационарности, т.е. длительность и перекрытие фрагментов; 2. он отличается от идеальной модели АР процесса; 3. заранее неизвестен порядок АР модели. Поэтому масштаб стационарности и порядок подбирается при помощи экспериментов с базой данных готового классификатора по критерию максимального процента правильной классификации. В итоге получаем оптимальное решение (классификатор, порядок, масштаб стационарности).

### 3. Нейронная сеть как классификатор

Одним из современных подходов к проблеме классификации сигналов являются нейронные сети. Пусть имеется  $N_i$  признаков, по которым сигнал относят к одному из  $N_o$  классов. Эти признаки составляют т.н. признаковое пространство, в котором формируются множества точек, каждое из которых представляет собой кластер класса. Задача классификатора заключается в том, чтобы по признакам сигнала отнести его к соответствующему кластеру.

Элементарной ячейкой нейронной сети является нейрон рис. 4, слева. Он представляет собой статический блок с несколькими входами и одним выходом. Весовое усреднение входов выполняет адаптивный сумматор, выход которого поступает на нелинейный преобразователь, выход которого и есть выход нейрона. В нейронной сети нейроны распределяются по слоям, входному, скрытым и выходному. Число входов нейрона равно числу нейронов в предыдущем слое. Входной слой состоит из  $N_i$  нейронов, выходной – из  $N_o$  нейронов, рис. 4, справа. При заданной архитектуре настраиваемыми параметрами сети являются веса нейронов. Процедура настройки весов называется режимом обучения сети. В режиме обучения для каждого класса задается эталонный выход сети и через нее пропускаются признаки сигналов из базы данных – обучающей выборки. При каждом проходе веса всех нейронов по определенному алгоритму настраиваются таким образом, чтобы в смысле некоторой меры минимально отличаться от эталонных выходов. Сеть считается обученной, когда исчерпана обучающая выборка, т.е. становится классификатором. В режиме классификации вектору признаков, поданному на вход обученной нейронной сети, сопоставляется метка того класса, для которого отклонение от соответствующего эталонного выхода минимальна. Тип сети определяет пара (архитектура, алгоритм обучения). Существует большое количество типов нейронных сетей. В задаче классификации наземной техники использовалась сеть с квантованием обучающего вектора (LVQ – Learning Vector Quantization).

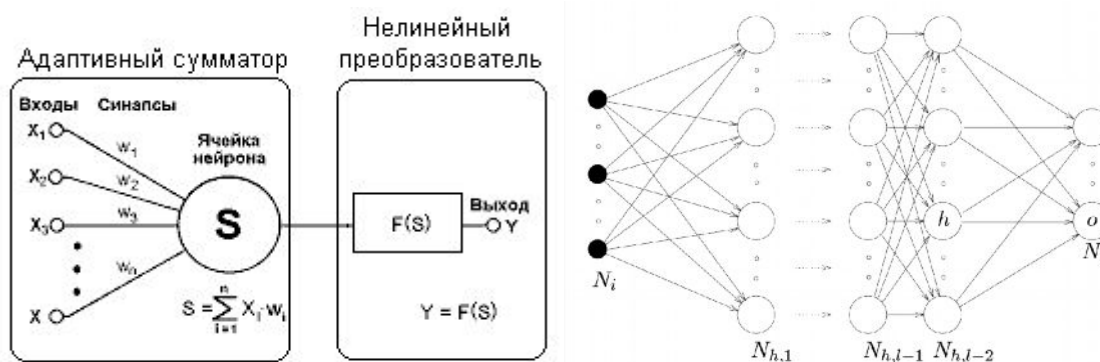


Рис.4. Слева: структура нейрона; справа: архитектура нейронной сети

### 4. LVQ сеть [3]

Архитектура сети LVQ приведена на рис. 5. Нейроны сети распределены по слоям: входном, скрытом и выходном слоях. Число нейронов входного слоя равно порядку АР модели. Число нейронов выходного слоя равно числу классов (=2). Скрытый слой содержит произвольное число нейронов  $2M$  (параметр сети). Множество нейронов скрытого слоя разбивается на два подмножества: множество, отвечающее за класс «Г» с индексами из  $I_\Gamma = \{1, 2, \dots, M\}$  и множество,

отвечающее за класс «K» с индексами из  $I_K = \{M+1, M+2, \dots, 2M\}$ .




Рис.5 Архитектура нейронной сети LVQ

Алгоритм обучения LVQ сети следующий. Перед началом первой итерации 2-векторы весов всех нейронов  $w_{(i)k}$   $i=1,2,\dots,2M$ ,  $k=1$ , скрытого слоя инициализируются. При подаче на вход сети первого обучающего вектора признаков  $x_k = [a_1, a_2]^T$  с  $k=1$  вычисляются расстояния между ним и векторами весов каждого нейрона  $w_{(i)k}$ :  $d_{(i)k} = \|x_k - w_{(i)k}\|_2$ , определяется нейрон-победитель, т.е. нейрон с индексом  $j$ , имеющий минимальный  $d_{(j)k}$ , все остальные расстояния приравниваются нулю. На выходе сети формируется выходной вектор  $y = \{[j, 0]^T, j \in I_\Gamma; [0, j]^T, j \in I_K\}$ , который сравнивается с эталоном  $z$ , где содержится информация о классе обучающего вектора  $x_k$ :  $z = \{[1, 0]^T, x_k \in \Gamma; [0, 1]^T, x_k \in K\}$ . Настройка вектора весов нейрона-победителя для  $(k+1)$ -й итерации зависит от результатов сравнения выхода нейронной сети с эталоном: если класс нейрона-победителя совпадает с классом  $x_k$ , то  $w_{(j)k}$  приближается к  $x_k$ :  $w_{(j)k+1} = w_{(j)k} + \gamma(x_k - w_{(j)k})$ , иначе – удаляется от него:  $w_{(j)k+1} = w_{(j)k} - \gamma(x_k - w_{(j)k})$ . Здесь  $\gamma$  – скорость обучения. Веса остальных нейронов остаются неизменными.

При классификации сравнивается расстояние между входным вектором признаков  $x$  и векторами весов всех нейронов. Выбирается  $j$ -й нейрон, имеющий минимальное  $d_{(j)} = \|x - w_{(j)}\|_2$ . Класс  $j$ -го нейрона определяет класс  $x$ .

#### 4. Практические результаты

LVQ – классификатор настраивался по обучающей выборке, составленной из 360 случайным образом выбранных сигналов в признаковом пространстве параметров АР модели второго порядка  $(a_1, a_2)$ . Обучающая выборка формировалась из фрагмента сигналов длительностью 2 секунды в окрестности энергетического максимума. Признакомое пространство, полученное по обучающей выборке, представлено на рис. 6, синий цвет – класс “колесо”, красный – “гусеница”. Из рис. видно, что признаки не хаотически перемешаны, а группируются в частично пересекающиеся области, что предварительно свидетельствует об их информативности. Количественную оценку последнего предположения дают результаты проверки классификатора на обучающей выборке. Векторы признаков, ошибочно отнесенные к другому классу, выделены на рис. 6 черными крестиками.




Рис.6. Признаковое пространство обучающей выборки

Результаты проверки следующие. Ошибочно классифицированных точек 54, правильно классифицированных 306. Вероятность правильной классификации  $P=306/360 \cdot 100\%=85\%$ . Кластеры классов LVQ классификатора показаны на рис. 7.




Рис.7. Кластеры классов LVQ классификатора

Эффективность работы классификатора определялась по тестовой выборке, в которую не вошли сигналы из обучающей выборки. Размер тестовой выборки – также 360 сигналов. На рис. 6 представлено признаковое пространство тестовой выборки, черными крестиками помечены неправильно классифицированные вектора признаков.




Рис.8. Признаковое пространство тестовой выборки

Результаты: ошибочно классифицированных точек 62, правильно классифицированных 298, всего 360, откуда вероятность правильной классификации  $P=298/360 \cdot 100\%=82,8\%$ . При увеличении порядка АР модели (4, 6, 8) эффективность классификатора не возрастала.

## 5. Заключение

Центральной проблемой задачи классификации является механизм извлечения информативных признаков из данных измерения. При наличии достоверной физической модели сигнала, содержащей физические параметры источника сигнала и характеристики среды распространения поля, возникает возможность дать количественную оценку этим величинам на основе экспериментальных данных через математическую структуру модели. Однако, во многих прикладных задачах в силу их специфических особенностей такую модель построить не удастся.

В настоящей работе рассматривается задача классификации движущихся объектов наземного транспорта с колесным и гусеничным шасси по сейсмическому сигналу. Сигнал от движущегося объекта является заведомо нестационарным и широкополосным случайным процессом, что не позволяет, используя идеализированные физические свойства объекта и среды, построить модель полезного сигнала.

Одна из альтернатив – непараметрическое или параметрическое оценивание оконного спектра сигнала. При непараметрическом оценивании в качестве признаков берутся коэффициенты спектральных отсчетов сигнала, а при параметрическом – сигналу сопоставляется некоторое множество параметров, много меньшее по сравнению с длиной сигнала. В настоящей работе использовалось параметрическое оценивание при помощи АР модели. Ее аксиоматика накладывает довольно серьезное ограничение на свойства сигнала как случайного процесса: он должен быть стационарным. Работа со спектром внутри скользящего окна в определенной мере смягчает эту проблему, но приводит в свою очередь к большим затратам по выбору ширины окна и степени перекрытия фрагментов.

Было установлено, что с точки зрения LVQ классификатора параметры АР модели второго порядка сейсмического сигнала с достаточным качеством различают колесную и гусеничную технику.

Полученный результат является основой дальнейший исследований, а именно:

- обработка только одного фрагмента, даже взятого вблизи траверса, т.е. предположительно с максимальным отношением сигнал/шум может оказаться недостаточным: близкие фрагменты также могут содержать информацию о классе объекта; т.к. большинство сигналов короткие, то

фактически необходима модель отношения сигнал/шум для делегирования фрагментов сигнала в обучающую выборку;

- классификатор на сети LVQ сети является лишь одним из возможных. Другие типы нейронных сетей могут оказаться более эффективными;
- спектральное представление сигнала также не является единственным, в Гильбертовом пространстве существуют и другие базисные разложения;
- актуальна проблема робастности классификаторов: условия, при которых записывались сигналы, вошедшие в обучающую выборку, могут существенно отличаться от условий работы классификатора;
- не решена проблема распознавания и классификации группового объекта (в нашем случае – колонны наземной техники).

#### Литература


1. Солонина А.И., Улахович Д.А., Арбузов С.М. и др. Основы цифровой обработки сигналов: Курс лекций – Спб. БХВ-Петербург, 2003.
2. S. Grassi. Optimized Implementation of Speech Processing Algorithms: Le rapport des members du jury - Universite de Neuchatel, 1998.
3. Kohonen, T., Self-Organizing Maps, Second Edition, Berlin - Springer-Verlag, 1997.

#### ДОПОЛНЕНИЕ

##### Классификатор на сети обратного распространения ошибки (Back Prop)

Датчик, принимающий сигналы от движущегося объекта, имеет 2 канала: сейсмический и акустический. Классификатор, построенный на сети LVQ [Д1], работает только по сейсмическому каналу. Причина в том, что привлечение акустического канала не дает заметного улучшения качества LVQ классификатора. В настоящем Дополнении к работе [Д1] оценивается классификатор, работающий по двум каналам на сети Back Prop.

На рис. Д1 приведены временная запись и спектрограмма в акустическом канале, соответствующие приведенным на рис. 2 в [Д1].






Рис. Д1. Временные сигналы и спектрограммы в акустическом канале от МТЛБУ, 31.08.04,  $v \approx 40$  км/час,  $d = 80$  м

#### Д1. Сеть Back Prop [Д2]

Рассмотрим многослойную сеть прямого распространения, рис. 4, справа. Обучение состоит в том, чтобы подобрать весовые коэффициенты, доставляющие минимум некоторой целевой функции. В качестве таковой берется сумма квадратов ошибок между эталонными выходами сети и выходами соответствующих нейронов выходного слоя по всем выходам и по всем элементам обучающей выборки.

$$E(w) = \sum_{j,p} (y_{j,p}^{(N_o)} - d_p)^2 \quad (Д1)$$

где  $y_{j,p}^{(N_o)}$  фактический выход  $p$ -го нейрона выходного слоя сети на  $j$ -м обучающем проходе,  $d_p$  желаемый выход. Поскольку  $y_{j,p}^{(N)}(w)$  - нелинейная функция, то используется метод наискорейшего спуска, т.е. на каждом шаге весовые коэффициенты корректируются по формуле

$$\Delta w_{ij}^{(n)} = -\eta \cdot \frac{\partial E}{\partial w_{ij}^{(n)}} \quad (Д2)$$

где  $w_{ij}^{(n)}$  весовой коэффициент, связывающий  $j$ -й нейрон  $n$ -го слоя с  $i$ -м нейроном  $(n-1)$ -го слоя,  $\eta$  - масштабный коэффициент.

Исходя из (Д2), следует определить частные производные целевой функции  $E$  по всем весовым коэффициентам. Дифференцируя  $E$  как сложную функцию, получим:

$$\frac{\partial E}{\partial w_{ij}^{(n)}} = \frac{\partial E}{\partial y_j^{(n)}} \cdot \frac{dy_j^{(n)}}{ds_j^{(n)}} \cdot \frac{\partial s_j^{(n)}}{\partial w_{ij}^{(n)}} \quad (Д3)$$

где  $y_j^{(n)}$  - выход, а  $s_j^{(n)}$  - взвешенная сумма входов  $j$ -го нейрона  $n$ -го слоя. Фиксируя передаточную функцию нейрона, вычисляем  $\frac{dy_j^{(n)}}{ds_j^{(n)}}$ : например, для функции  $f(x) = \frac{1}{1 + e^{-\alpha x}}$  (сигмоидальной) получаем

$$\frac{dy_j^{(n)}}{ds_j^{(n)}} = \alpha y_j^{(n)} (1 - y_j^{(n)}) \cdot \quad (Д4)$$

Третий множитель  $\partial s_j^{(n)} / \partial w_{ij}^{(n)}$  есть выход  $i$ -го нейрона  $(n-1)$ -го слоя, то есть

$$\frac{\partial s_j^{(n)}}{\partial w_{ij}^{(n)}} = y_i^{(n-1)}.$$

Дифференцируя (Д1) по  $y_j^{(N)}$ , с учетом (Д3) и (Д4) получим



$$\frac{\partial E}{\partial w_{ij}^{(N)}} = (y_j^{(N)} - d_j) \cdot \frac{dy_j^{(N)}}{ds_j^{(N)}} \cdot y_i^{(N-1)}$$

Введем обозначение

$$\delta_j^{(n)} = \frac{\partial E}{\partial y_j^{(n)}} \cdot \frac{dy_j^{(n)}}{ds_j^{(n)}}.$$

Тогда для нейронов выходного слоя

$$\delta_j^{(N)} = (y_j^{(N)} - d_j) \cdot \frac{dy_j^{(N)}}{ds_j^{(N)}}. \quad (Д5)$$

Представим 1-й сомножитель в правой части (Д3) в виде

$$\frac{\partial E}{\partial y_j^{(n)}} = \sum_k \frac{\partial E}{\partial y_k^{(n+1)}} \cdot \frac{dy_k^{(n+1)}}{ds_k^{(n+1)}} \cdot \frac{ds_k^{(n+1)}}{\partial y_j^{(n)}} = \sum_k \frac{\partial E}{\partial y_k^{(n+1)}} \cdot \frac{dy_k^{(n+1)}}{ds_k^{(n+1)}} \cdot w_{jk}^{(n+1)}$$

Заметим, что произведение 1-х двух сомножителей есть  $\delta_k^{(n+1)}$ . Отсюда выражаем  $\delta_j^{(n)}$  (для нейронов n-го слоя) в терминах  $\delta_k^{(n+1)}$  (для нейронов (n+1)-го). Для последнего слоя  $\delta_j^{(N)}$  вычисляется по (Д5), откуда с помощью рекурсивной формулы

$$\delta_j^{(n)} = \left[ \sum_k \delta_k^{(n+1)} \cdot w_{jk}^{(n+1)} \right] \cdot \frac{dy_j^{(n)}}{ds_j^{(n)}} \quad (Д6)$$

получаем  $\delta_j^{(n)}$  для всех нейронов всех слоев.

Окончательно, соотношение (Д2) для коррекции весов записывается в виде

$$\Delta w_{ij}^{(n)} = -\eta \cdot \delta_j^{(n)} \cdot y_i^{(n-1)}. \quad (Д7)$$

Сформулируем алгоритм обучения:

- 1) Подаем на вход сети один из обучающих векторов. Вычисляем выходные значения сети, запоминая при этом выходные значения каждого из нейронов.
- 2) Рассчитываем  $\delta_j^{(N)}$  (Д5). Рассчитываем все остальные  $\delta_j^{(n)}$  (Д6). Рассчитываем приращение весов (Д7).
- 3) Корректируем веса:  $w_{ij}^{(n)} = w_{ij}^{(n)} + \Delta w_{ij}^{(n)}$

и переходим к следующему обучающему вектору. Один “прогон” всей обучающей выборки называется эпохой. Количество эпох является одной из “регулировок” алгоритма обучения.

## Д2. Практические результаты

Признаковое пространство обучающей выборки и кластеры классов обученного Back Prop классификатора (в проекции) иллюстрируются на рис Д2 и Д3 (синий – колесо, красный – гусеница). Результаты работы Back Prop классификатора на тестовой выборке представлены на рис. Д4, на котором проекции неправильно классифицированных точек помечены черным цветом. Количественные результаты экспериментов таковы: сейсмический сигнал AP2 – 78,0%; акустический и сейсмический сигналы AP2 – 86,1%; акустический и сейсмический сигналы AP4 – 90,9%; акустический и сейсмический сигналы AP6 – 92,8%; акустический и сейсмический сигналы AP8 – 93,7%.




Рис. Д2. Признаковое пространство обучающей выборки

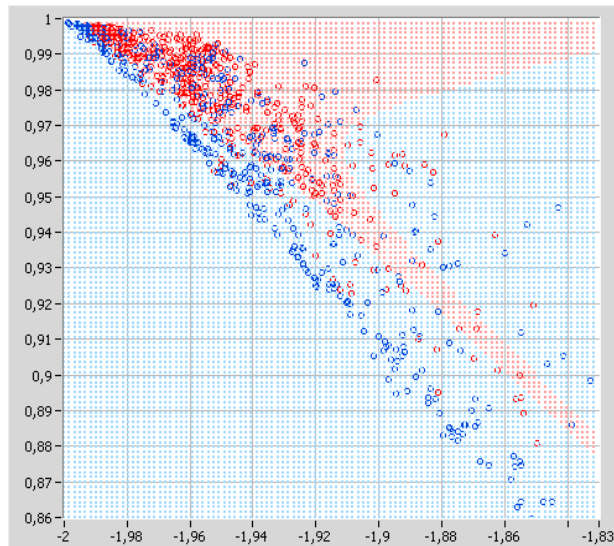


Рис.Д3. Кластеры классов сети Back Prop




Рис. ПЗ. Признаковое пространство тестовой выборки сети Back Prop

### ДЗ. Заключение

Back Prop классификатор превосходит LVQ классификатор за счет использования информации акустического канала. Известно, что акустический сигнал от движущегося объекта является более зашумленным. Следовательно, Back Prop классификатор лучше работает с зашумленными сигналами.

### Литература

- Д1. Бузуверов Г.В., Герасимов О.И. Классификация наземных транспортных средств по параметрам авторегрессионной модели сигнала с применением нейронных сетей. Материалы конференции «Научные, инженерные и производственные проблемы создания технических средств мониторинга электромагнитного поля»/ФГУП «НИИ «Вектор»», СПб, 2005г., 86-88.
- Д2. Hagan, M. T., H. B. Demuth, and M. H. Beale, Neural Network Design, Boston, MA: PWS Publishing, 1996.